Evaluación comparativa de redes de clasificación RGB para el diagnóstico de enfermedades en piña

Proyecto MERCOIA — Informe técnico

Jose Barrios
Universidad Industrial de Santander

Octubre de 2026

Resumen

Se repitió para la piña (*Ananas comosus*) la evaluación comparativa realizada con la mora: ocho arquitecturas de clasificación de imágenes RGB, entre redes convolucionales, transformers y modelos fundacionales congelados, entrenadas con tres niveles de aumento de datos sobre una partición estratificada 70/15/15 por clase y agrupada por fruto, para distinguir dos estados: sana y fusariosis. El conjunto de entrenamiento actual de piña tiene 70 imágenes originales y el de prueba 9. Con el aumento base, cinco redes acertaron las 9 imágenes de prueba y el promedio fue de 93.1 % de exactitud y 0.842 de F1 macro. EfficientNet-B0, EfficientNetV2-S y MobileNetV3-L acertaron todo con aumento base y fuerte; sin aumento, las redes ligeras cayeron hasta 55.6 %, y ConvNeXt-T y ViT-B/16 clasificaron como fusariosis todas las piñas sanas. Con 9 imágenes de prueba el intervalo de confianza de un 9/9 va de 66.4 % a 100 %, así que estos resultados validan el protocolo pero no permiten elegir red ni afirmar una exactitud de diagnóstico. El informe documenta además que la clase "fusariosis" de entrenamiento mezcla varias enfermedades y fotos sin etiqueta, y que existen 494 recortes etiquetados y 665 sin etiquetar que todavía no participan del entrenamiento. Las limitaciones se discuten en la Sección 6.

1. Objetivo

El pipeline de MERCOIA segmenta el fruto con SAM 3 y clasifica el recorte para dar un diagnóstico a partir de una foto de celular. Este informe aplica a la piña el mismo banco de pruebas usado con la mora, con tres preguntas: (i) qué arquitectura ofrece el mejor desempeño con el dataset actual de piña; (ii) cuánto aporta el aumento de datos; (iii) qué costo computacional tiene cada red para un despliegue móvil. Una cuarta pregunta, implícita, es si el dataset actual de piña permite responder las tres anteriores.

2. Datos

2.1. Conjunto de datos

Se usaron los recortes de piña segmentados con SAM 3 que están en el directorio `Algorithm/data`, en dos clases: `pina_sana` (28 originales) y `pina_fusariosis` (42 originales). Ambas clases traen copias aumentadas precalculadas en disco (`aug_*`, cinco por original), que solo se usan para entrenar. En total son 70 imágenes originales, menos de una cuarta parte de las 328 con que se entrenó la mora.

2.2. Partición

La partición es la misma de la mora: 70 % de los frutos de cada clase a entrenamiento, 15 % a validación y 15 % a prueba, con el fruto como unidad para que los recortes de una misma

foto no se repartan entre conjuntos, semilla 42. Las copias `aug_*` se asignan al conjunto de su original y se descartan de validación y prueba. La Tabla 1 muestra los conteos resultantes. El conjunto de prueba tiene 9 imágenes, y solo 2 de ellas son sanas.

Tabla 1: Imágenes por conjunto y clase (piña, partición 70/15/15 por fruto).

Conjunto	Sana	Fusariosis	Total
Entrenamiento (originales)	24	29	53
Entrenamiento (con copias `aug_*`)	144	174	318
Validación	2	6	8
Prueba	2	7	9

3. Metodología

3.1. Arquitecturas

Son las ocho redes del estudio de mora (Tabla 2): CNN ligeras pensadas para móvil, una CNN moderna, transformers de visión y un modelo fundacional autosupervisado usado como extractor congelado con sonda lineal [2, 4, 3, 5, 6, 7, 8]. En todas se reemplazó la capa de clasificación por una capa lineal de dos salidas.

Tabla 2: Arquitecturas evaluadas.

Red	Familia	Parám. (M)	Preentrenamiento	Ajuste
EfficientNet-B0	CNN móvil	4.0	ImageNet-1k	completo
MobileNetV3-L	CNN móvil	4.2	ImageNet-1k	completo
EfficientNetV2-S	CNN	20.2	ImageNet-1k	completo
ConvNeXt-T	CNN moderna	27.8	ImageNet-1k	completo
Swin-T	Transformer jerárquico	27.5	ImageNet-1k	completo
ViT-B/16	Transformer	85.8	ImageNet-1k	completo
DINOv2 ViT-S/14	Fundacional	22.1	LVD-142M (autosup.)	sonda lineal
DINOv2 ViT-B/14	Fundacional	86.6	LVD-142M (autosup.)	sonda lineal

3.2. Protocolo de entrenamiento

Idéntico al de la mora, sin ajustar ningún hiperparámetro a la piña:

- Pérdida de entropía cruzada y optimizador SGD con momento 0.9 y *weight decay* 5×10^{-4}.
- Tasa de aprendizaje inicial de 0.01, reducida por un factor de 0.1 en las épocas 20 y 30.
- 40 épocas, lote de 64 y resolución de 224×224, con precisión mixta (AMP).
- Las sondas lineales de DINOv2 usan tasa de 0.1 y lote de 128.
- Se guarda el checkpoint con mayor exactitud de validación y con él se evalúa la prueba.

Con 318 imágenes de entrenamiento (53 sin aumento) cada época tiene entre 1 y 5 lotes, de modo que las 40 épocas equivalen a 40–200 pasos de gradiente. Durante este estudio se corrigió un detalle del cargador de datos: cuando el conjunto de entrenamiento tiene menos imágenes que el tamaño de lote ($53 < 64$, en el nivel sin aumento), la configuración original descartaba el lote incompleto y la red no entrenaba ningún paso; la primera corrida sin aumento dio resultados de azar por esta causa y se repitió con el cargador corregido. Los resultados de este informe son los de la corrida corregida. El entrenamiento se hizo en una NVIDIA GeForce RTX 4070 de 12 GB, con registro en Weights & Biases (proyecto `MercoIA/clasificacion_frutas`).

3.3. Niveles de aumento de datos

`none` Sin aumento en línea y sin copias `aug_*`: solo las 53 originales.

`base` Recorte aleatorio (escala 0.85–1.0), volteo horizontal y vertical, rotación de ±15° con relleno blanco y variación de color suave, más las copias `aug_*`.

`fuerte` `base` más TrivialAugmentWide [1].

3.4. Métricas y medición de costo

Se reportan la exactitud y el F1 macro. El F1 macro es la métrica principal porque la clase sana tiene solo 2 imágenes de prueba: una red que clasifique todo como fusariosis obtiene 77.8 % de exactitud pero 0.438 de F1 macro. El costo en inferencia se midió con lote 1, entrada de 224×224 y *autocast* fp16, con 30 pasadas de calentamiento y la mediana de 200 pasadas sincronizadas. La memoria es el pico reservado por PyTorch durante la inferencia.

4. Resultados

4.1. Desempeño en prueba

La Tabla 3 muestra la exactitud y el F1 macro en prueba de las 24 corridas.

Tabla 3: Exactitud y F1 macro en el conjunto de prueba ($n = 9$: 7 fusariosis, 2 sanas) según el nivel de aumento. En negrita, el mejor valor de cada fila.

	`none`		`base`		`fuerte`	
Red	Exact.	F1	Exact.	F1	Exact.	F1
EfficientNet-B0	0.556	0.550	**1.000**	**1.000**	**1.000**	**1.000**
EfficientNetV2-S	0.778	0.750	**1.000**	**1.000**	**1.000**	**1.000**
MobileNetV3-L	0.667	0.585	**1.000**	**1.000**	**1.000**	**1.000**
ConvNeXt-T	**0.778**	**0.750**	0.778	0.438	0.778	0.438
Swin-T	**1.000**	**1.000**	**1.000**	**1.000**	0.889	0.862
ViT-B/16	**1.000**	**1.000**	0.778	0.438	0.667	0.649
DINOv2-S (lineal)	**1.000**	**1.000**	0.889	0.862	**1.000**	**1.000**
DINOv2-B (lineal)	**1.000**	**1.000**	**1.000**	**1.000**	**1.000**	**1.000**
Promedio	0.847	0.829	**0.931**	0.842	0.917	**0.869**

Tres observaciones se sostienen a pesar del tamaño del conjunto de prueba:

- Las tres CNN ligeras (EfficientNet-B0, EfficientNetV2-S y MobileNetV3-L) aciertan las 9 imágenes con aumento `base` y `fuerte`, igual que en la mora.
- Sin aumento, esas mismas redes se desploman: EfficientNet-B0 cae a 55.6 %. Con 53 imágenes y un solo lote por época, 40 épocas son 40 pasos de gradiente; las copias `aug_*` son las que sostienen el entrenamiento de la piña.
- ConvNeXt-T y ViT-B/16 con aumento clasifican como fusariosis todas las piñas sanas. Las curvas de la Figura 1 muestran la causa: la exactitud de entrenamiento de ConvNeXt-T con `base` y `fuerte` nunca supera 0.73 y termina en 0.55, que es exactamente la fracción de fusariosis en el conjunto de entrenamiento (174 de 318). La red colapsó a la clase mayoritaria con la tasa de aprendizaje de 0.01, que fue heredada de la mora y no se ajustó para una red grande con tan pocos lotes.

4.2. Curvas de aprendizaje

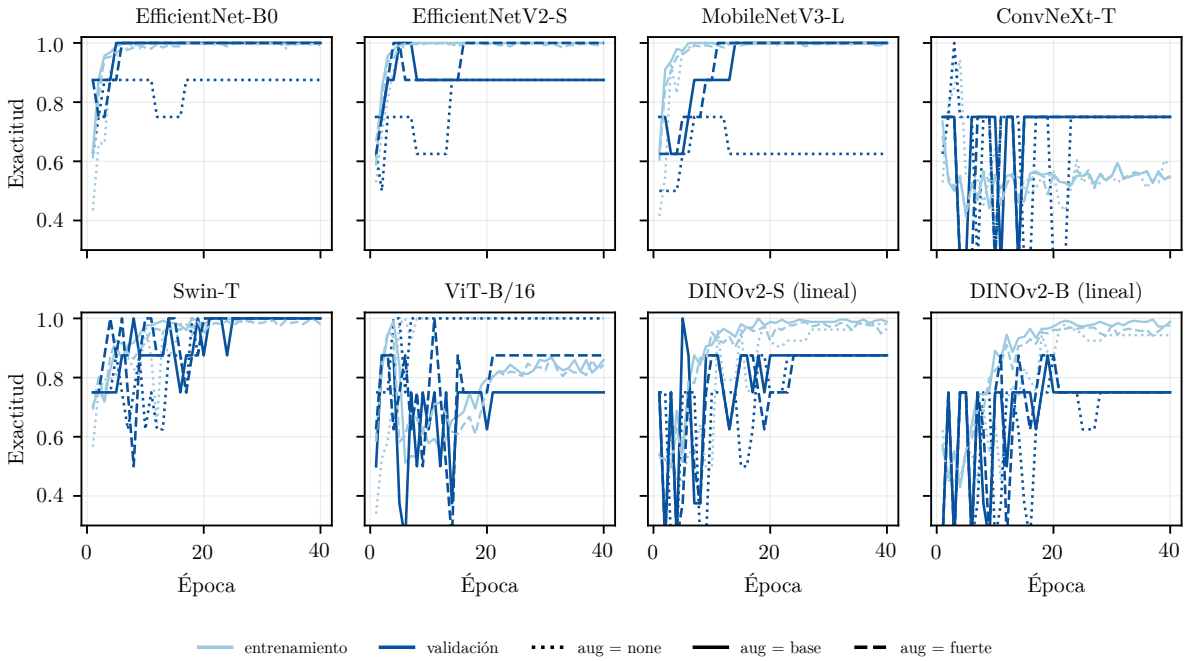


Figura 1: Exactitud por época en entrenamiento (azul claro) y validación (azul oscuro) para los tres niveles de aumento. La validación tiene 8 imágenes, por eso solo toma los valores 0.62, 0.75, 0.88 y 1.00.

La Figura 1 muestra tres comportamientos. Las CNN ligeras, Swin-T y las sondas de DINOv2 llegan al 100 % de entrenamiento en pocas épocas y mantienen la validación en 0.88–1.00. ConvNeXt-T con aumento se queda en 0.55 de entrenamiento durante las 40 épocas, el colapso descrito arriba; ViT-B/16 con `base` y `fuerte` oscila y termina por debajo de 0.90. Sin aumento todas las redes memorizan las 53 originales, pero MobileNetV3-L termina con 0.62 de validación y EfficientNet-B0, que alcanza 0.88 en validación, falla 4 de las 7 fusariosis de prueba. Con 8 imágenes de validación la selección del mejor checkpoint es poco fiable: un cambio en una imagen mueve la validación 12.5 puntos.

4.3. Matrices de confusión

La Figura 2 muestra las matrices de prueba con el aumento `base`; el Anexo A trae las de entrenamiento, validación y prueba de las 24 corridas. Los errores tienen dos signos opuestos según el nivel de aumento:

- **Con aumento, falsas alarmas.** ConvNeXt-T y ViT-B/16 clasifican las 2 sanas como fusariosis. DINOv2-S con `base` y Swin-T con `fuerte` fallan una fusariosis cada una.
- **Sin aumento, falsos negativos.** EfficientNet-B0 clasifica como sanas 4 de las 7 fusariosis; EfficientNetV2-S, MobileNetV3-L y ConvNeXt-T, 2 cada una. Para el agricultor, este es el error que importa: una piña enferma que pasa por sana.

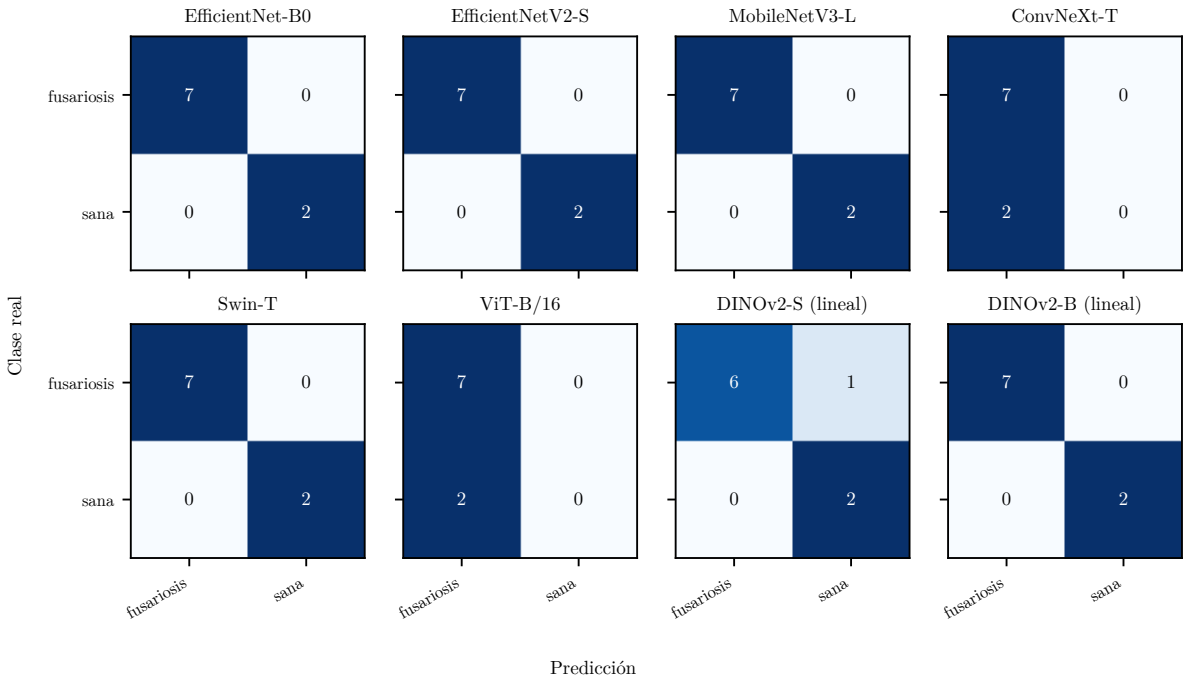


Figura 2: Matrices de confusión en prueba con aumento `base`. El número es el conteo de imágenes y el color, la proporción por fila.

4.4. Costo computacional

La Tabla 4 y la Figura 3 resumen el costo de cada red con aumento `base`. Los tiempos de inferencia y la memoria coinciden con los medidos en la mora, como corresponde a arquitecturas idénticas; la única diferencia es ConvNeXt-T, que en la mora mostró tiempos inestables (18–45 ms) y aquí midió 6.9 ms de forma estable. Los tiempos de entrenamiento son algo mayores que en la mora porque estas corridas compartieron la máquina con otro entrenamiento simultáneo.

Tabla 4: Costo computacional con aumento `base` (RTX 4070, lote 1, fp16, 224 × 224). El tiempo de entrenamiento corresponde a 40 épocas.

Red	Parám. (M)	Pesos (MB)	Entren. (min)	Inferencia (ms/img)	Memoria inf. (MB)
EfficientNet-B0	4.0	15.6	4.0	9.6	**52**
MobileNetV3-L	4.2	16.2	4.0	7.2	53
EfficientNetV2-S	20.2	77.8	4.1	20.5	209
DINOv2-S (lineal)	22.1	84.2	6.1	8.3	188
Swin-T	27.5	105.3	4.1	14.3	290
ConvNeXt-T	27.8	106.2	4.1	6.9	291
DINOv2-B (lineal)	86.6	330.3	6.4	8.0	680
ViT-B/16	85.8	327.4	4.2	**6.8**	846

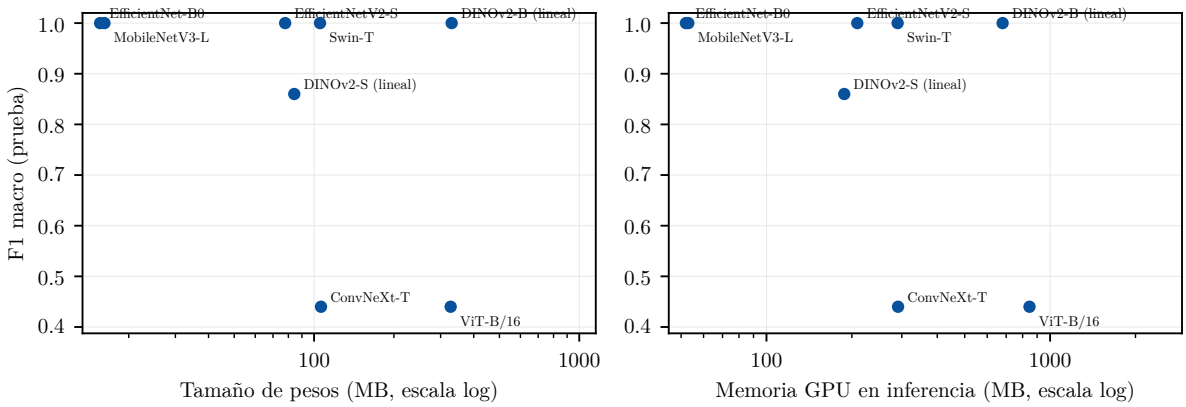


Figura 3: Relación entre F1 macro en prueba y tamaño del modelo (izquierda) o memoria en inferencia (derecha), con aumento `base`.

Como en la mora, el tiempo de inferencia en GPU con lote 1 favorece a ViT-B/16 por razones ajenas a su costo real en un celular; en el teléfono mandan los pesos y la memoria, y ahí EfficientNet-B0 y MobileNetV3-L ocupan veinte veces menos que ViT-B/16 y DINOv2-B con el mismo resultado en prueba.

5. Discusión

Con 9 imágenes de prueba, el intervalo de Clopper–Pearson al 95 % es [0.664, 1.000] para 9/9 aciertos y [0.400, 0.972] para 7/9. Todos los intervalos de la Tabla 3 se solapan, así que el conjunto de prueba actual no permite ordenar las redes ni distinguir entre niveles de aumento. Lo que sí permite es descartar configuraciones que fallan de forma sistemática: ConvNeXt-T y ViT-B/16 con la tasa de aprendizaje actual, y cualquier red sin aumento.

Dentro de esos límites, la elección provisional coincide con la de la mora: EfficientNet-B0 con aumento `base`, por ser la red más liviana entre las que aciertan todo, con 15.6 MB de pesos y 52 MB en inferencia. MobileNetV3-L es la alternativa equivalente. Usar la misma red para las dos frutas simplifica además el despliegue.

6. Limitaciones

Conjunto de prueba diminuto. Nueve imágenes, dos de ellas sanas. Cada imagen vale 11 puntos de exactitud y cada sana vale 50 puntos de la sensibilidad de esa clase. Es la limitación que invalida cualquier lectura fina de la Tabla 3.

Etiquetas de la clase fusariosis. Al cruzar las 42 imágenes originales de `pina_fusariosis` con el registro de etiquetado (`etiquetas.csv`) resulta que solo 1 está etiquetada como fusarium; 10 están etiquetadas como pudrición, 3 como *sana*, 1 como phytophthora y 27 no tienen etiqueta registrada. De las 28 `pina_sana`, 1 está etiquetada como pudrición. Es decir, la clase que el modelo aprende como “fusariosis” es en realidad “varias enfermedades más fotos sin etiquetar”. Cualquier conclusión sobre fusariosis en particular queda sin sustento.

Confusión entre clase y sesión de captura. Las 28 sanas provienen de dos sesiones del 19 de mayo (`cap1_19may`, `cap2_19may`); las “fusariosis” vienen de `cap2_12jun` (14), `Pina_Jul_25` (10), fotos sueltas, de Internet y de WhatsApp (16) y solo 2 de las sesiones del 19 de mayo. Una red puede separar las clases por la sesión sin mirar el fruto, como se discutió para la mora.

Datos etiquetados sin usar. El registro de etiquetado contiene 494 recortes de piña que no participan del entrenamiento: 432 sanas, 28 con pudrición, 15 con afectación externa, 15 con phytophthora y 4 con fusarium. Además hay 665 recortes nuevos, de cinco sesiones (19 de mayo, 12 y 26 de junio, 25 de julio y 26 de septiembre), segmentados y pendientes de etiquetar. El entrenamiento actual usa el 12 % de los recortes de piña disponibles.

Hiperparámetros heredados. La tasa de aprendizaje, el tamaño de lote y el número de épocas se tomaron de la mora sin ajustar. El colapso de ConvNeXt-T y la inestabilidad de ViT-B/16 son consecuencia de esa decisión y no una propiedad de las arquitecturas.

Una sola semilla y medición en GPU de escritorio. Igual que en la mora: no se estimó la variabilidad entre repeticiones, y los tiempos no sustituyen una medición en el dispositivo móvil.

7. Conclusiones y trabajo futuro

1. El banco de pruebas funciona sin cambios para la piña: las 24 corridas se ejecutaron con el mismo protocolo, el mismo registro y las mismas métricas que la mora, y dejó corregido un defecto del cargador de datos que afectaba a cualquier fruta con menos originales que el tamaño de lote.

2. Con el dataset actual, EfficientNet-B0 con aumento `base` es la elección provisional, la misma que en la mora, lo que permite un único modelo ligero por fruta en la aplicación. La elección es provisional porque el conjunto de prueba no la respalda estadísticamente.

3. El aumento de datos es imprescindible en piña: sin las copias `aug_*` las redes ligeras no alcanzan a entrenar.

4. El dataset es el límite, con más claridad aún que en la mora. Antes de repetir estos experimentos conviene: (a) definir el esquema de clases de piña: con lo etiquetado hoy, el único esquema con datos suficientes es sana frente a enferma (432 contra unas 100), agrupando pudrición, afectación externa, phytophthora y fusarium; (b) reconstruir `Algorithm/data` desde `etiquetas.csv`, para que cada imagen de entrenamiento tenga etiqueta y sesión trazables; (c) etiquetar los 665 recortes nuevos, que aportan sesiones distintas y, con ellas, un conjunto de prueba de otro día; (d) ajustar la tasa de aprendizaje de las redes grandes o descartarlas, y repetir con varias semillas y con partición por sesión.

Referencias

[1] S. G. Müller y F. Hutter, "TrivialAugment: Tuning-free yet state-of-the-art data augmentation," en *ICCV*, 2021.

[2] M. Tan y Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," en *ICML*, 2019.

[3] M. Tan y Q. V. Le, "EfficientNetV2: Smaller models and faster training," en *ICML*, 2021.

[4] A. Howard *et al.*, "Searching for MobileNetV3," en *ICCV*, 2019.

[5] Z. Liu *et al.*, "A ConvNet for the 2020s," en *CVPR*, 2022.

[6] Z. Liu *et al.*, "Swin Transformer: Hierarchical vision transformer using shifted windows," en *ICCV*, 2021.

[7] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," en *ICLR*, 2021.

[8] M. Oquab *et al.*, "DINOv2: Learning robust visual features without supervision," *TMLR*, 2024.

A. Matrices de confusión por red

En cada figura, las filas corresponden al nivel de aumento (`none`, `base`, `fuerte`) y las columnas, al conjunto (entrenamiento solo con originales, validación y prueba). En todos los casos se usa el mejor checkpoint por exactitud de validación.

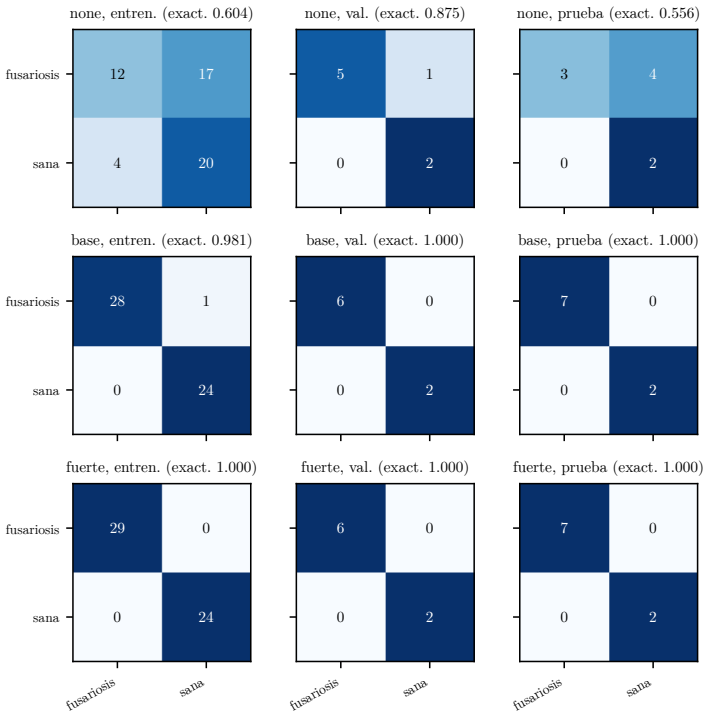


Figura 4: EfficientNet-B0.

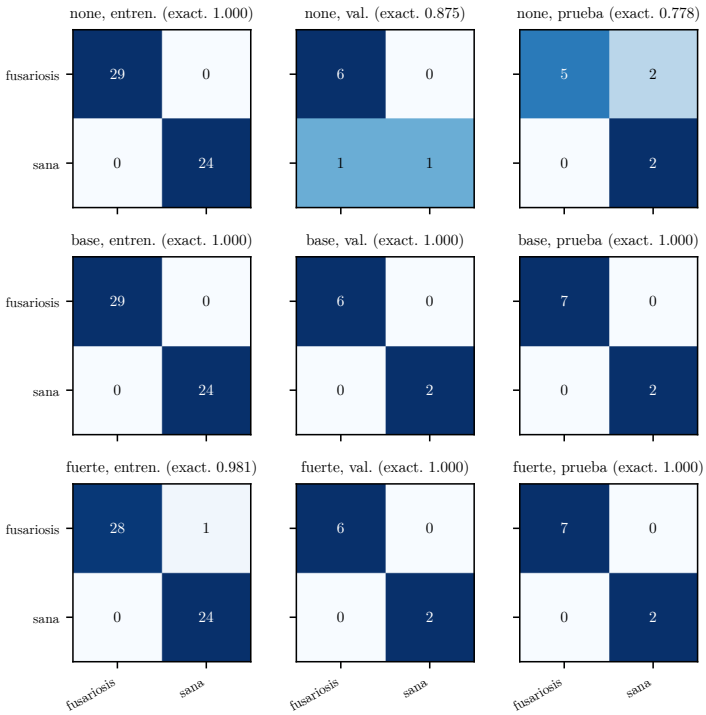


Figura 5: EfficientNetV2-S.

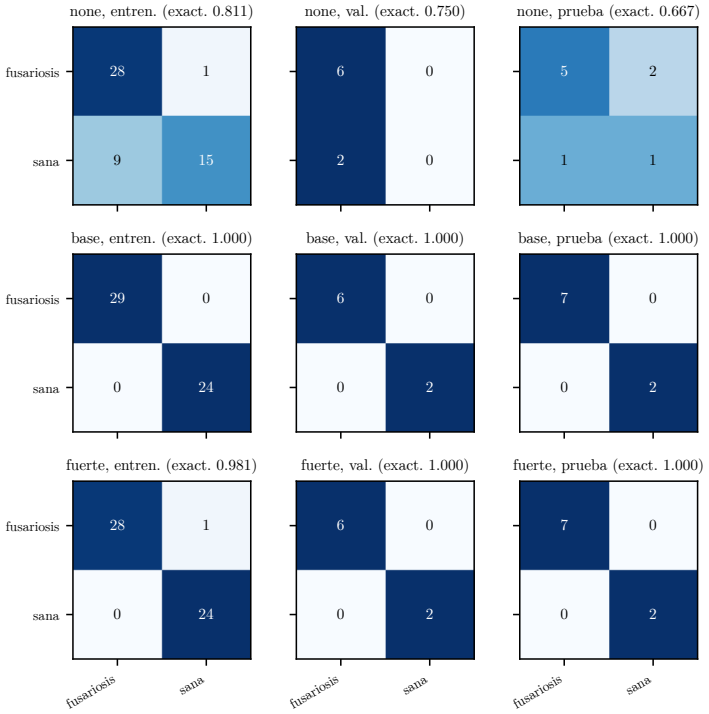


Figura 6: MobileNetV3-L.

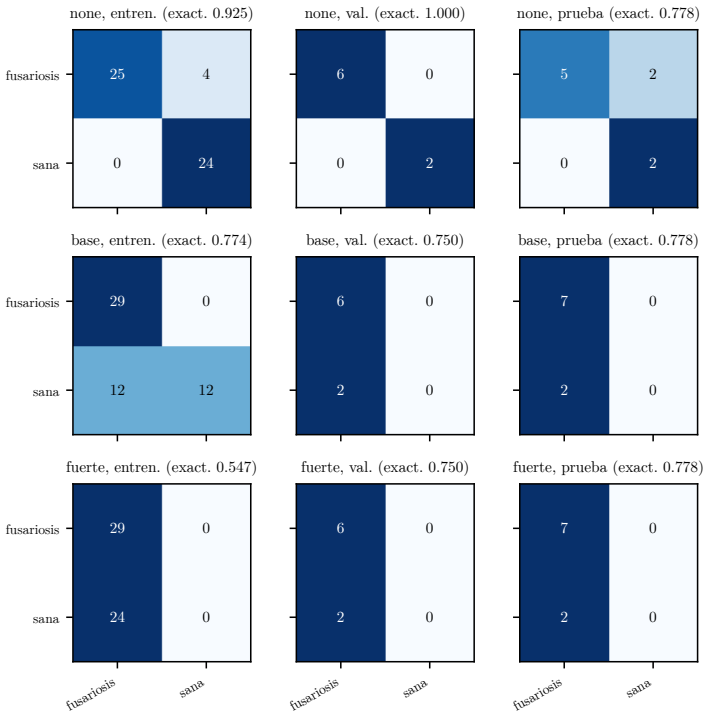


Figura 7: ConvNeXt-T.

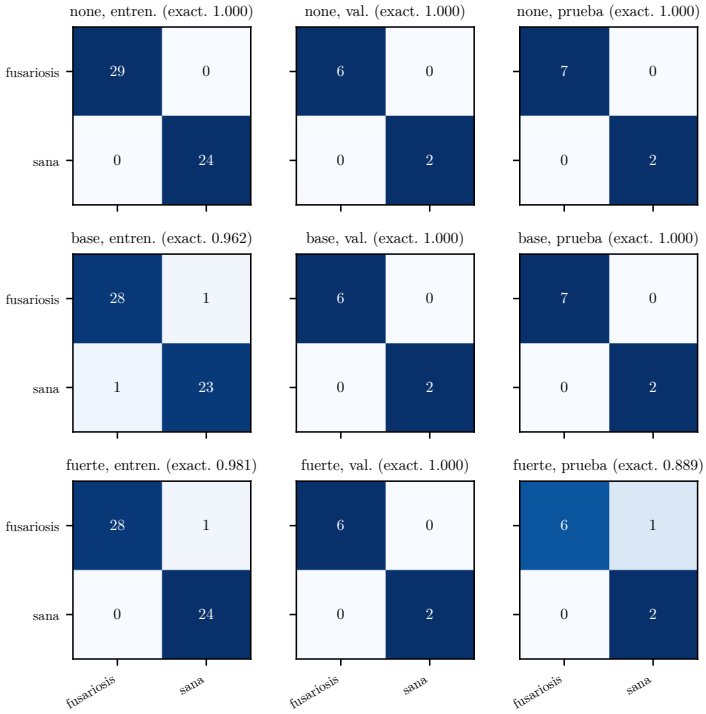


Figura 8: Swin-T.

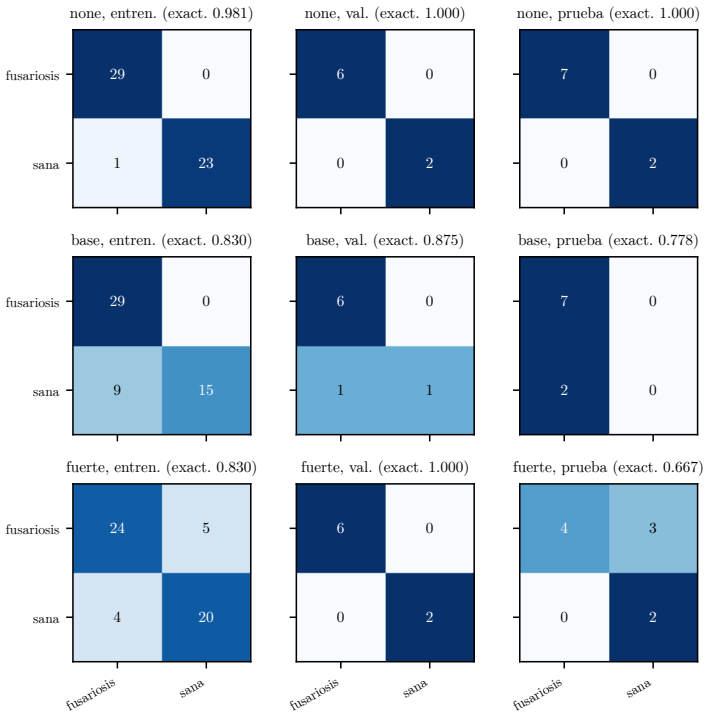


Figura 9: ViT-B/16.

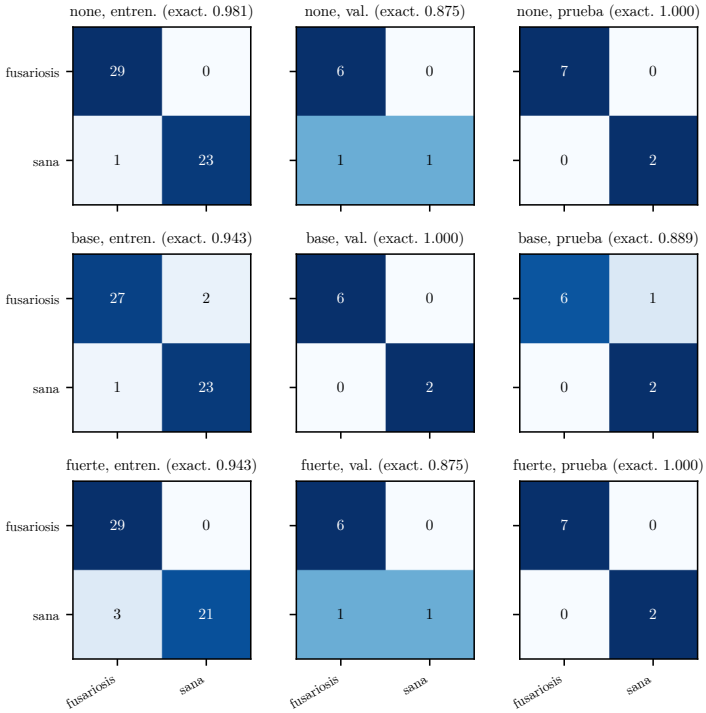


Figura 10: DINOv2 ViT-S/14, sonda lineal.

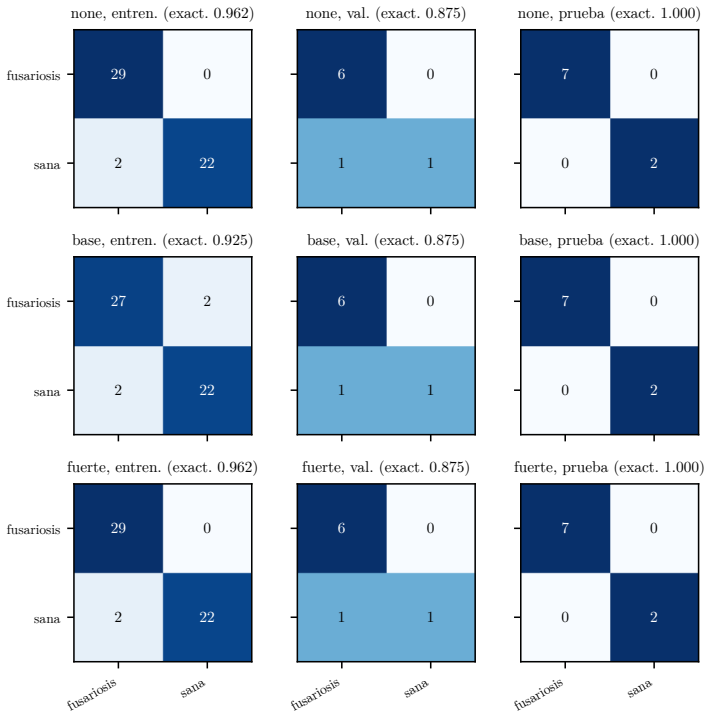


Figura 11: DINOv2 ViT-B/14, sonda lineal.