Evaluación comparativa de redes de clasificación RGB para el diagnóstico de enfermedades en piña

Segunda ronda: dataset reconstruido desde el registro de etiquetado
Proyecto MERCOIA — Informe técnico

Jose Barrios
Universidad Industrial de Santander

Octubre de 2026

Resumen

La primera ronda de experimentos con piña (*Ananas comosus*) entrenó con 70 imágenes y evaluó con 9, y concluyó que el dataset, no la arquitectura, era el límite. En esta segunda ronda el conjunto de entrenamiento se reconstruyó desde el registro de etiquetado (`etiquetas.csv`), la única fuente con etiquetas verificadas, con dos clases: sana (432 recortes) y enferma (62 recortes: pudrición, afectación externa, phytophthora y fusarium). La partición 70/15/15 por fruto deja 324 originales en entrenamiento, 96 en validación y 74 en prueba (66 sanas, 8 enfermas); el desbalance se compensa con pérdida ponderada por clase y, en dos de los tres niveles de aumento, con copias aumentadas de la clase minoritaria. Se entrenaron las mismas ocho arquitecturas con tres niveles de aumento, 24 corridas. Sin aumento el promedio fue de 97.6 % de exactitud y 0.941 de F1 macro, y tres redes acertaron las 74 imágenes de prueba (EfficientNetV2-S, MobileNetV3-L y DINOv2-S); con aumento `base` y `fuerte` los promedios fueron 95.6 % y 95.8 %. Las dos clases provienen en su mayoría de la misma sesión de captura, de modo que, a diferencia de las rondas anteriores, el modelo no puede separar las clases reconociendo la sesión. Las imágenes en las que fallan casi todas las redes resultaron estar etiquetadas como "afectación externa", un daño mecánico y no una enfermedad, lo que motiva revisar el esquema de clases. Con 8 enfermas en prueba los intervalos de confianza siguen siendo anchos; las limitaciones se discuten en la Sección 6.

1. Objetivo

Repetir la evaluación comparativa de clasificadores para piña con un dataset defendible: etiquetas trazables, las dos clases de la misma sesión de captura y un conjunto de prueba con decenas de imágenes en lugar de nueve. Las preguntas son las de siempre: qué arquitectura rinde mejor, cuánto aporta el aumento de datos y qué costo tiene cada red para el despliegue móvil. Se añade una cuarta: qué dice el patrón de errores sobre el etiquetado.

2. Datos

2.1. Construcción del dataset

El dataset anterior de piña (`Algorithm/data`) se había armado a mano: de sus 42 imágenes de "fusariosis" solo una estaba registrada como fusarium, y 27 no tenían etiqueta. En esta ronda el conjunto se construye con un script (`construir_dataset.py`) que lee `etiquetas.csv`, copia cada recorte de `dataset_segm/Pinas` a la carpeta de su clase de entrenamiento según el mapa de la Tabla 1, y genera cinco copias aumentadas en disco (`aug_*`) solo para las clases con menos de la mitad de imágenes que la mayoritaria. El resultado queda en `Algorithm/data_etq` y se

regenera desde cero en cada ejecución, de modo que al etiquetar más recortes basta con volver a correrlo.

Tabla 1: Mapa de clases: del registro de etiquetado a las clases de entrenamiento.

Clase en `etiquetas.csv`	Clase de entrenamiento	Recortes
`pina_sana`	`pina_sana`	432
`pina_pudricion`	`pina_enferma`	28
`pina_afectacion_externa`	`pina_enferma`	15
`pina_phytopthora`	`pina_enferma`	15
`pina_fusarium`	`pina_enferma`	4
Total enferma		62 (54 fotos)

2.2. Origen de las imágenes

Las sanas provienen de `cap2_12jun` (241), `cap1_19may` (146) y `cap2_19may` (44); las enfermas, de `cap2_12jun` (40), `Pina_Jul_25` (16), `cap1_19may` (2) y cuatro fotos sueltas. La sesión principal, `cap2_12jun`, contiene las dos clases. Esto importa: en la mora y en la primera ronda de piña cada clase venía casi de una sola sesión, y una red podía separarlas por la iluminación o la cámara sin mirar el fruto. Aquí ese atajo no alcanza.

2.3. Partición

Misma regla que en las rondas anteriores: 70 % de las fotos de cada clase a entrenamiento, 15 % a validación y 15 % a prueba, con la foto como unidad para que los recortes de una misma piña no se repartan entre conjuntos; semilla 42; las copias `aug_*` siguen a su original y solo entran en entrenamiento (Tabla 2).

Tabla 2: Imágenes por conjunto y clase (partición 70/15/15 por foto).

Conjunto	Sana	Enferma	Total
Entrenamiento (originales)	280	44	324
Entrenamiento (con copias `aug_*`)	280	264	544
Validación	86	10	96
Prueba	66	8	74

3. Metodología

3.1. Arquitecturas y protocolo

Las ocho redes y el protocolo son los de las rondas anteriores [2, 4, 3, 5, 6, 7, 8]: EfficientNet-B0, MobileNetV3-L, EfficientNetV2-S, ConvNeXt-T, Swin-T y ViT-B/16 ajustadas por completo desde ImageNet-1k, y DINOv2 ViT-S/14 y ViT-B/14 congeladas con sonda lineal; entropía cruzada y SGD (momento 0.9, *weight decay* 5×10^{-4}), tasa 0.01 con caídas $\times 0.1$ en las épocas 20 y 30 (0.1 para las sondas), 40 épocas, lote 64 (128 para las sondas), 224×224, precisión mixta; mejor checkpoint por exactitud de validación. Dos diferencias respecto a la primera ronda:

- **Pérdida ponderada por clase** (`-balance`): el peso de la clase k es $N/(K\,n_k)$ sobre el conjunto de entrenamiento. Sin copias `aug_*` vale 3.7 para enferma y 0.58 para sana; con copias, 1.03 y 0.97, porque las copias ya equilibran. La validación y la prueba se evalúan con la pérdida sin pesos.

- El cargador de datos conserva el último lote incompleto cuando el conjunto de entrenamiento es menor que el lote, defecto corregido en la primera ronda.

Las corridas se ejecutaron de dos en dos, una por GPU (RTX 4070, 12 GB), con registro en Weights & Biases.

3.2. Niveles de aumento

`none` Sin aumento en línea y sin copias `aug_*`: 324 originales, con la pérdida ponderada como único mecanismo de balanceo.

`base` Recorte aleatorio, volteos, rotación de ±15° con relleno blanco y variación de color suave, más las 220 copias `aug_*` de enferma que caen en entrenamiento.

`fuerte` `base` más TrivialAugmentWide [1].

3.3. Métricas y costo

Exactitud y F1 macro (métrica principal: con 8 enfermas en prueba, una red que diga "sana" a todo obtiene 89 % de exactitud y 0.47 de F1). El costo se midió como en las rondas anteriores: lote 1, 224 × 224, fp16, mediana de 200 pasadas tras 30 de calentamiento, memoria pico de PyTorch.

4. Resultados

4.1. Desempeño en prueba

Tabla 3: Exactitud y F1 macro en prueba ($n = 74$: 66 sanas, 8 enfermas). En negrita, el mejor valor de cada fila.

	`none`		`base`		`fuerte`	
Red	Exact.	F1	Exact.	F1	Exact.	F1
EfficientNet-B0	**0.973**	**0.930**	0.946	0.874	**0.973**	**0.930**
EfficientNetV2-S	**1.000**	**1.000**	0.960	0.900	0.946	0.874
MobileNetV3-L	**1.000**	**1.000**	0.973	0.937	0.973	0.937
ConvNeXt-T	0.905	0.767	0.905	0.806	**0.919**	**0.810**
Swin-T	0.960	0.900	**0.973**	**0.930**	0.946	0.874
ViT-B/16	**0.987**	**0.967**	0.946	0.874	0.973	0.930
DINOv2-S (lineal)	**1.000**	**1.000**	0.960	0.889	0.960	0.874
DINOv2-B (lineal)	0.987	0.963	**0.987**	**0.967**	0.973	0.930
Promedio	**0.976**	**0.941**	0.956	0.897	0.958	0.895

Tres resultados:

- **Sin aumento es el mejor nivel**, por 2 puntos de exactitud y 4.5 de F1 macro en promedio, y tres redes aciertan las 74 imágenes. Es lo contrario de la primera ronda, donde sin aumento las redes ligeras caían al 55 %. La diferencia es el tamaño del conjunto: con 324 originales reales ya hay con qué entrenar, y la pérdida ponderada sustituye a las copias de disco. Las transformaciones en línea (recorte aleatorio, rotación con relleno blanco) deforman recortes que ya vienen centrados y, como muestra la Sección 4.3, inducen falsas alarmas.

- **Las redes ligeras siguen en el grupo de cabeza**: MobileNetV3-L y EfficientNetV2-S aciertan todo sin aumento y quedan entre 94.6 y 97.3 % con aumento.
- **ConvNeXt-T es la peor en los tres niveles** (90–92 %), pero ahora aprende: en la primera ronda colapsaba a la clase mayoritaria.

4.2. Curvas de aprendizaje

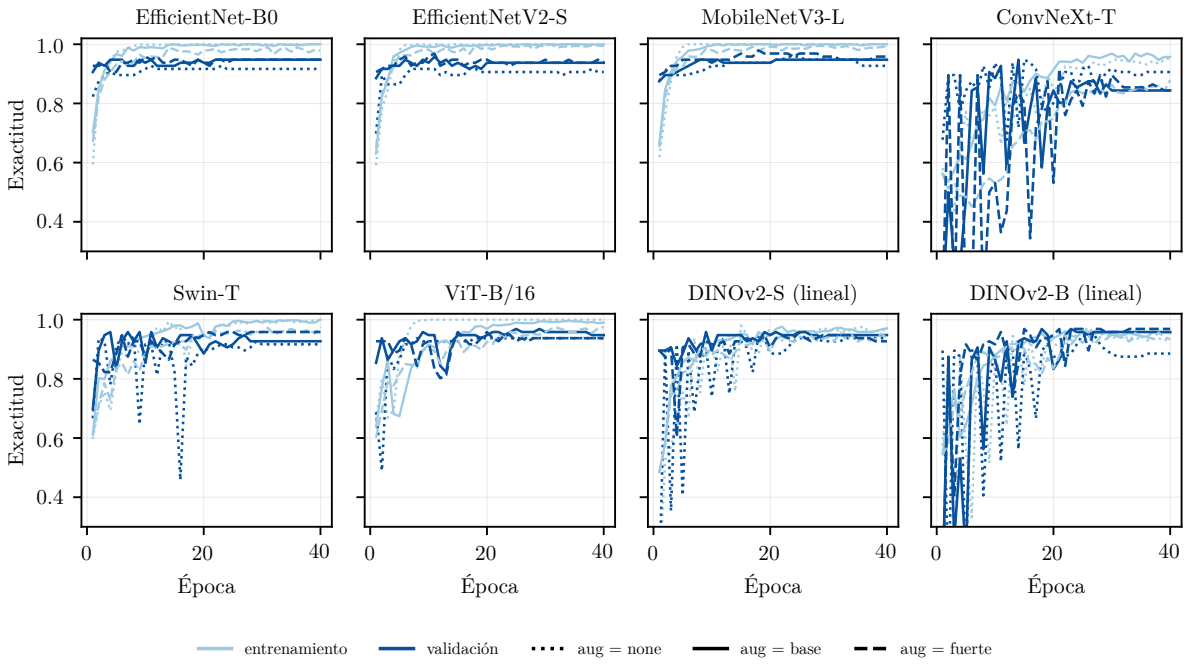


Figura 1: Exactitud por época en entrenamiento (azul claro) y validación (azul oscuro) para los tres niveles de aumento. La validación tiene 96 imágenes.

Con 96 imágenes de validación cada imagen vale un punto, y las curvas son por fin legibles (Figura 1). El entrenamiento llega a 95–100 % en todas las corridas. La validación máxima está entre 0.92 y 0.98, se alcanza entre las épocas 4 y 25, y al final de las 40 épocas se mantiene a menos de 2 puntos del máximo en 21 de las 24 corridas. Las excepciones, donde hay un sobreajuste leve, son ConvNeXt-T con `base` (0.948 en la época 14, 0.844 al final) y DINOv2-B sin aumento (0.948 en la época 25, 0.885 al final).

4.3. Matrices de confusión

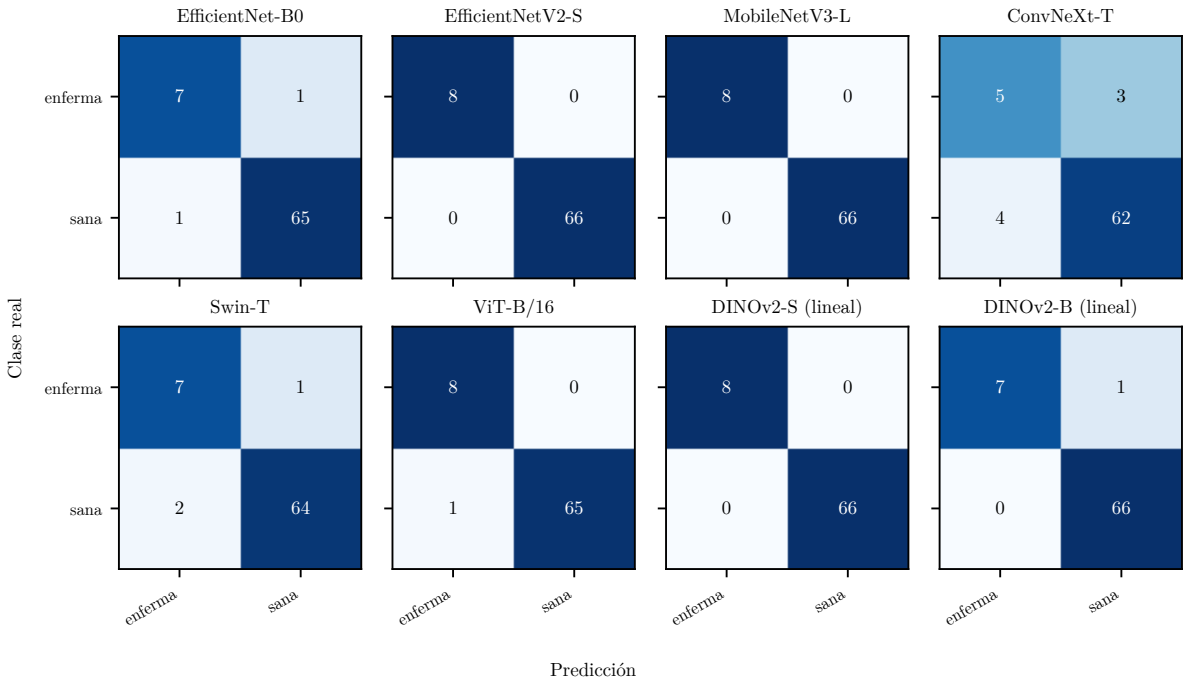


Figura 2: Matrices de confusión en prueba sin aumento (`none`). El número es el conteo de imágenes y el color, la proporción por fila.

La Figura 2 muestra las matrices de prueba sin aumento; las de los tres niveles y los tres conjuntos están en el Anexo A. Dos lecturas:

- **Sensibilidad en enfermas.** Sin aumento, cinco redes detectan las 8 enfermas y tres detectan 7; con aumento, casi todas detectan 7 de 8 y es siempre la misma piña la que se escapa (`cap2_12jun_205`, etiquetada pudrición). Para el agricultor este es el error que importa, y queda en 0 o 1 de 8.
- **Falsas alarmas y aumento.** Las matrices de entrenamiento sobre las imágenes originales explican la ventaja de `none`: con aumento, las redes clasifican como enfermas entre 6 y 15 piñas sanas del propio conjunto de entrenamiento (EfficientNet-B0 con `base`: 15 de 280), mientras que sin aumento lo ajustan por completo. El aumento en línea empuja a las redes hacia la clase enferma, y eso se traduce en 1 a 6 falsas alarmas en prueba frente a 0 a 2 sin aumento.

4.4. Imágenes en las que fallan todas las redes

Al cruzar los errores de las ocho redes con aumento `base` aparecen cuatro imágenes que fallan la mayoría (Figura 3). Dos de ellas, etiquetadas como afectación externa, las ocho redes las llaman sanas: son piñas de aspecto sano con un corte o golpe en la base, un daño mecánico que no es una enfermedad y que apenas se ve en el recorte. Una tercera, etiquetada como sana, seis de ocho redes la llaman enferma: tiene una mancha parda extensa en un costado. La cuarta, etiquetada pudrición, es una piña madura sin lesión visible en el recorte. Cuando ocho arquitecturas distintas coinciden en el mismo error, la hipótesis más económica es que la etiqueta o el recorte son el problema.



Figura 3: Imágenes falladas por cuatro o más de las ocho redes (aumento `base`), con su conjunto, su etiqueta en `etiquetas.csv` y cuántas redes fallan.

4.5. Costo computacional

Tabla 4: Costo computacional con aumento `base` (RTX 4070, lote 1, fp16, 224 × 224). Entrenamiento de 40 épocas con 544 imágenes, dos corridas simultáneas por máquina.

Red	Parám. (M)	Pesos (MB)	Entren. (min)	Inferencia (ms/img)	Memoria inf. (MB)
EfficientNet-B0	4.0	15.6	4.9	15.9	**52**
MobileNetV3-L	4.2	16.2	4.9	11.8	53
EfficientNetV2-S	20.2	77.8	5.9	33.9	209
DINOv2-S (lineal)	22.1	84.2	5.9	13.1	188
Swin-T	27.5	105.3	6.3	25.8	291
ConvNeXt-T	27.8	106.2	5.7	11.8	291
DINOv2-B (lineal)	86.6	330.3	6.7	12.4	680
ViT-B/16	85.8	327.4	7.3	**7.9**	848

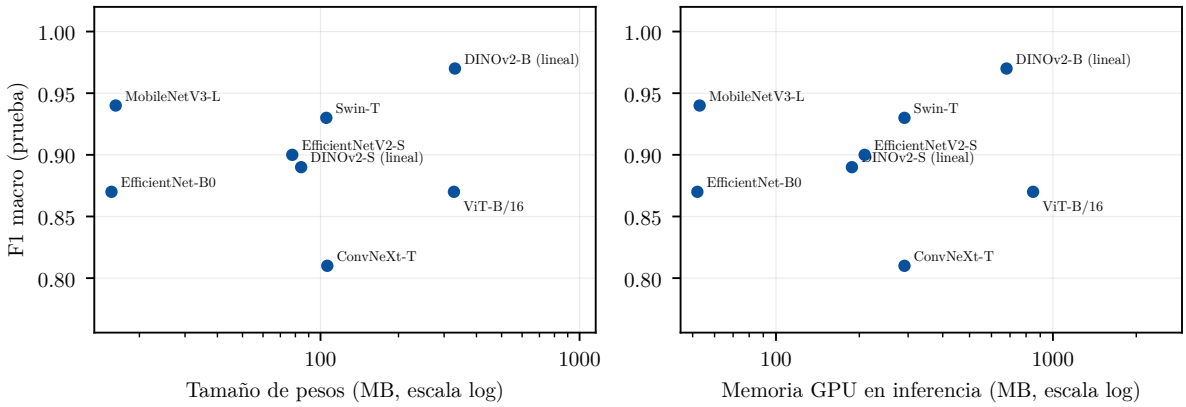


Figura 4: Relación entre F1 macro en prueba y tamaño del modelo (izquierda) o memoria en inferencia (derecha), con aumento `base`.

Los parámetros, los pesos y la memoria son idénticos a los de las rondas anteriores, como corresponde a las mismas arquitecturas. Los tiempos de inferencia de esta sesión son entre 1.4 y 1.7 veces mayores que los medidos en la primera ronda de piña para todas las redes por igual, lo que apunta al estado de reloj de la GPU y no a las redes; el orden relativo se conserva y, como antes, el tiempo en GPU con lote 1 no predice el del celular, donde mandan los pesos y la memoria.

5. Discusión

Con 74 imágenes de prueba, el intervalo de Clopper–Pearson al 95 % es [0.951, 1.000] para 74/74 aciertos, [0.906, 0.997] para 72/74 y [0.815, 0.961] para 67/74. Los intervalos de las redes del grupo de cabeza se solapan, pero el conjunto ya separa a ConvNeXt-T del resto y ya permite afirmar que la tarea sana/enferma se resuelve por encima del 90 % dentro de la distribución de estas sesiones. En la primera ronda, 9/9 tenía un intervalo de [0.664, 1.000].

La ventaja de `none` debe leerse con cuidado: con 8 enfermas en prueba, la diferencia entre 100 % y 97.3 % es una o dos imágenes. Lo que sí es consistente en los tres conjuntos es que el aumento en línea genera falsas alarmas sobre piñas sanas, incluidas las del propio entrenamiento. Para piña, la pérdida ponderada basta como mecanismo de balanceo y el aumento en línea actual conviene revisarlo (menos recorte y rotación, o ninguno) antes que mantenerlo por defecto.

La elección para la aplicación se mantiene en las redes ligeras: **MobileNetV3-L** es la más consistente (0 enfermas perdidas en los tres niveles, 74/74 sin aumento) y pesa 16 MB; EfficientNetV2-S iguala el 74/74 pero pesa 78 MB; EfficientNet-B0 queda a una imagen. DINOv2-S también acierta todo sin aumento, pero con pérdida de prueba 0.000, señal de la sobreconfianza de las sondas lineales ya vista en la mora, y con 84 MB.

6. Limitaciones

Pocas enfermas en prueba. Ocho. La sensibilidad en enfermas solo puede tomar los valores $k/8$, y una imagen mueve el F1 macro unos 6 puntos. Es la limitación principal y solo se corrige etiquetando más enfermas.

Esquema de clases. "Enferma" agrupa cuatro condiciones, y una de ellas, afectación externa (15 recortes), es daño mecánico. Las dos imágenes que fallan las ocho redes pertenecen a esa clase. Agruparla con las enfermedades le pide al modelo que detecte cortes y golpes apenas visibles; conviene sacarla de la clase enferma o tratarla aparte cuando haya más ejemplos. Con 4, 15 y 28 recortes, distinguir pudrición, phytophthora y fusarium entre sí sigue sin ser viable.

Una etiqueta dudosa. La imagen `cap2_12jun_185`, etiquetada sana, muestra una mancha parda extensa y seis de ocho redes la clasifican como enferma. Debe revisarse.

Sesiones. Aunque las dos clases comparten `cap2_12jun`, el 79 % de las sanas y el 65 % de las enfermas vienen de esa sesión, y la prueba sale de las mismas sesiones que el entrenamiento. Los 665 recortes nuevos pendientes de etiquetar, de cinco sesiones distintas, son el camino a una prueba de otro día.

Hiperparámetros, semilla y medición. Igual que antes: tasa de aprendizaje heredada de la mora, una sola semilla, costo medido en GPU de escritorio.

7. Conclusiones y trabajo futuro

1. Reconstruir el dataset desde el registro de etiquetado cambió la naturaleza de los resultados: de 9 imágenes de prueba de otra sesión a 74 de la misma sesión con etiquetas trazables. Es el cambio que más ha movido el proyecto de piña, y no tocó ninguna red.

2. Con ese dataset, la tarea sana/enferma se resuelve con 95–100 % de exactitud en prueba, y las redes ligeras están en el grupo de cabeza. **MobileNetV3-L sin aumento** es la elección provisional para la aplicación.

3. El aumento en línea actual perjudica en piña: induce falsas alarmas sobre sanas. La pérdida ponderada por clase es suficiente para el desbalance.

4. El patrón de errores detectó dos problemas de etiquetado: la clase afectación externa no es una enfermedad y una imagen sana parece mal etiquetada. Revisar las etiquetas a partir de los errores consistentes entre redes es un procedimiento barato que conviene repetir en cada ronda.

5. Siguientes pasos, en orden: (a) sacar afectación externa de la clase enferma y revisar `cap2_12jun_185`, reconstruir y repetir `none`; (b) etiquetar los 665 recortes nuevos y reservar una sesión completa como prueba; (c) repetir con tres semillas y seleccionar el checkpoint por pérdida de validación; (d) medir el modelo elegido en el celular.

Referencias

[1] S. G. Müller y F. Hutter, "TrivialAugment: Tuning-free yet state-of-the-art data augmentation," en *ICCV*, 2021.

[2] M. Tan y Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," en *ICML*, 2019.

[3] M. Tan y Q. V. Le, "EfficientNetV2: Smaller models and faster training," en *ICML*, 2021.

[4] A. Howard *et al.*, "Searching for MobileNetV3," en *ICCV*, 2019.

[5] Z. Liu *et al.*, "A ConvNet for the 2020s," en *CVPR*, 2022.

[6] Z. Liu *et al.*, "Swin Transformer: Hierarchical vision transformer using shifted windows," en *ICCV*, 2021.

[7] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," en *ICLR*, 2021.

[8] M. Oquab *et al.*, "DINOv2: Learning robust visual features without supervision," *TMLR*, 2024.

A. Matrices de confusión por red

En cada figura, las filas corresponden al nivel de aumento (`none`, `base`, `fuerte`) y las columnas, al conjunto (entrenamiento solo con originales, validación y prueba). En todos los casos se usa el mejor checkpoint por exactitud de validación.

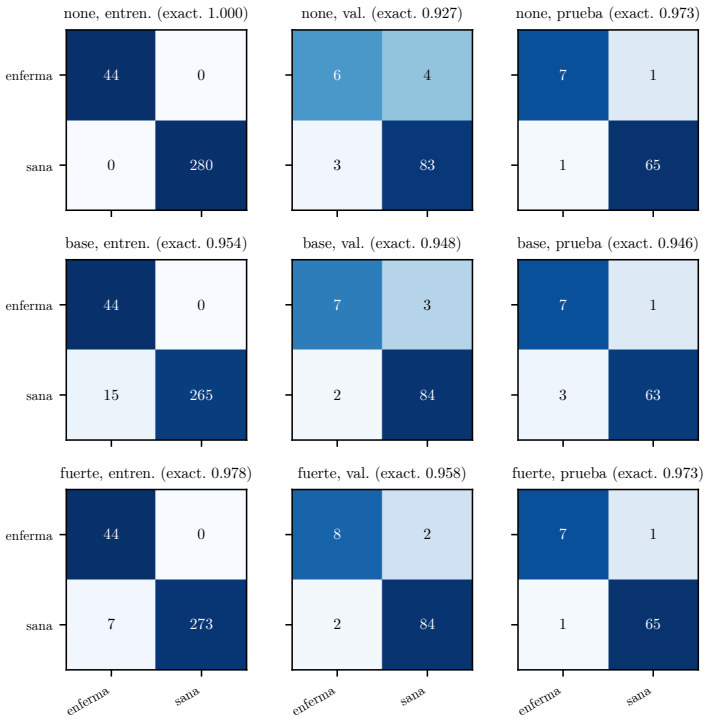


Figura 5: EfficientNet-B0.

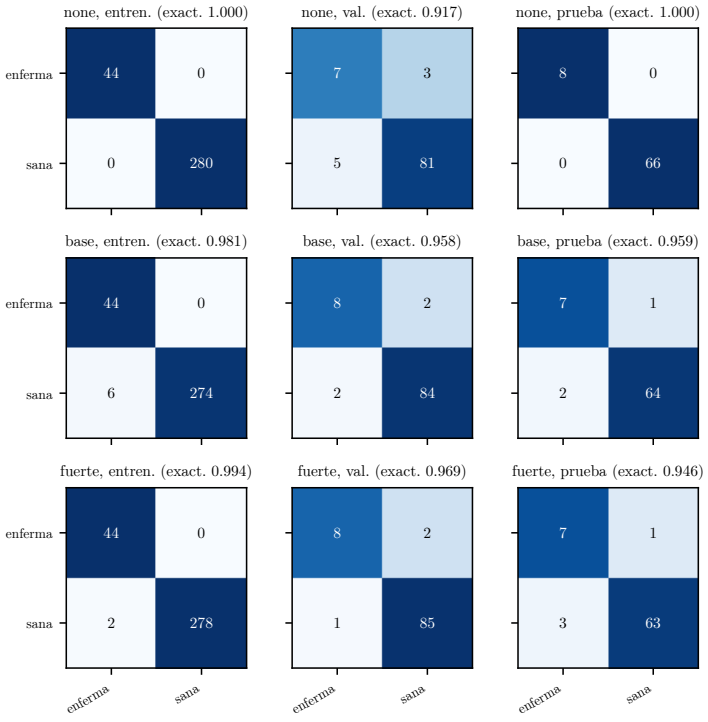


Figura 6: EfficientNetV2-S.

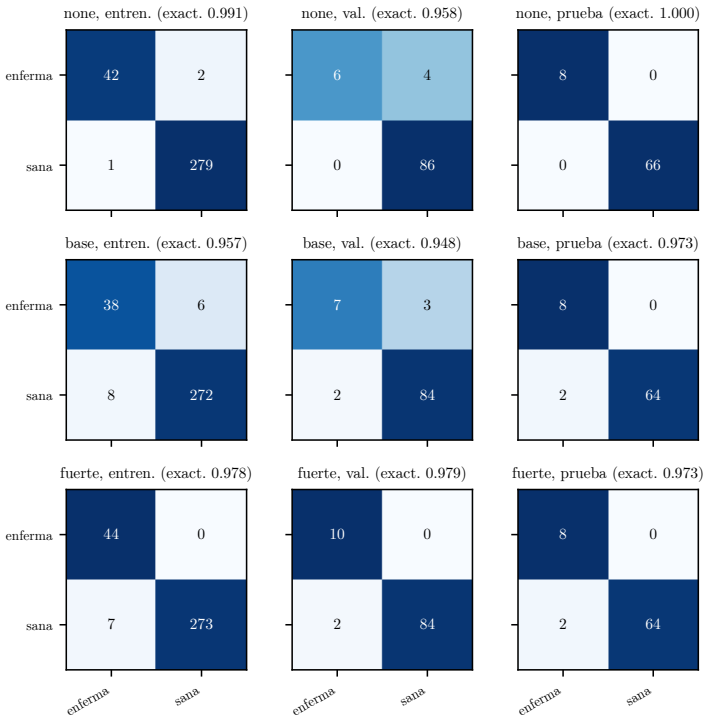


Figura 7: MobileNetV3-L.

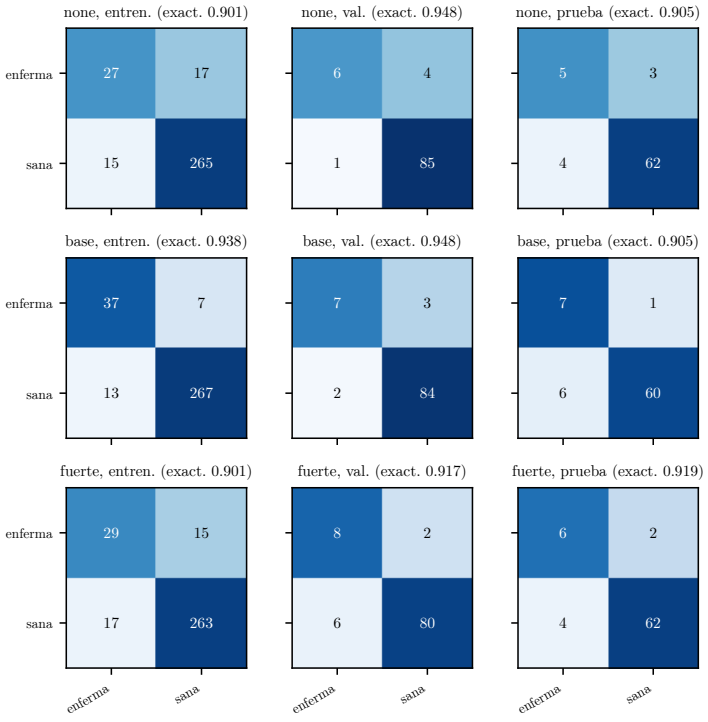


Figura 8: ConvNeXt-T.

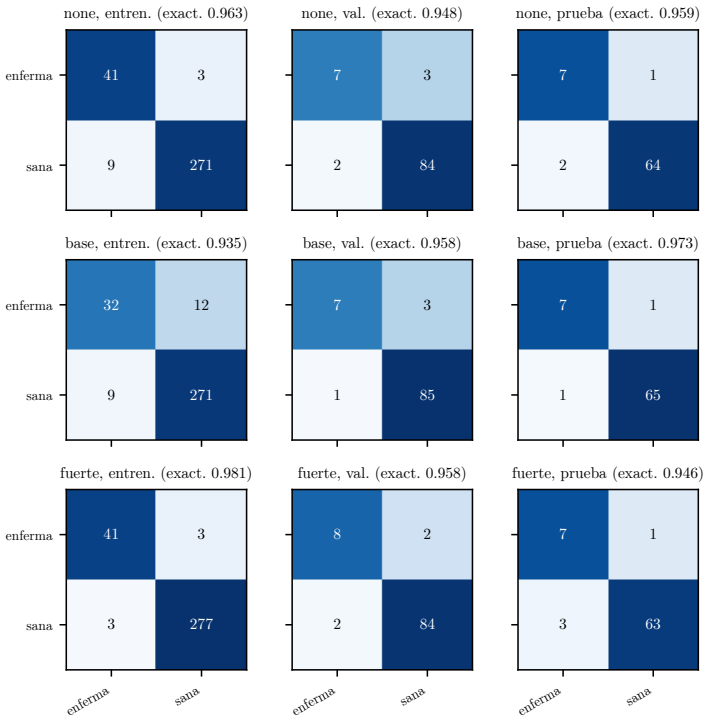


Figura 9: Swin-T.

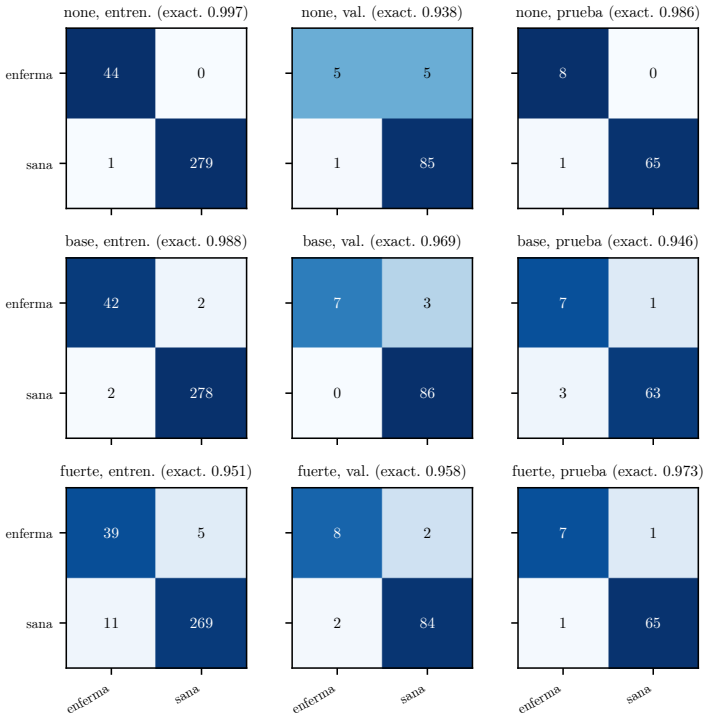


Figura 10: ViT-B/16.

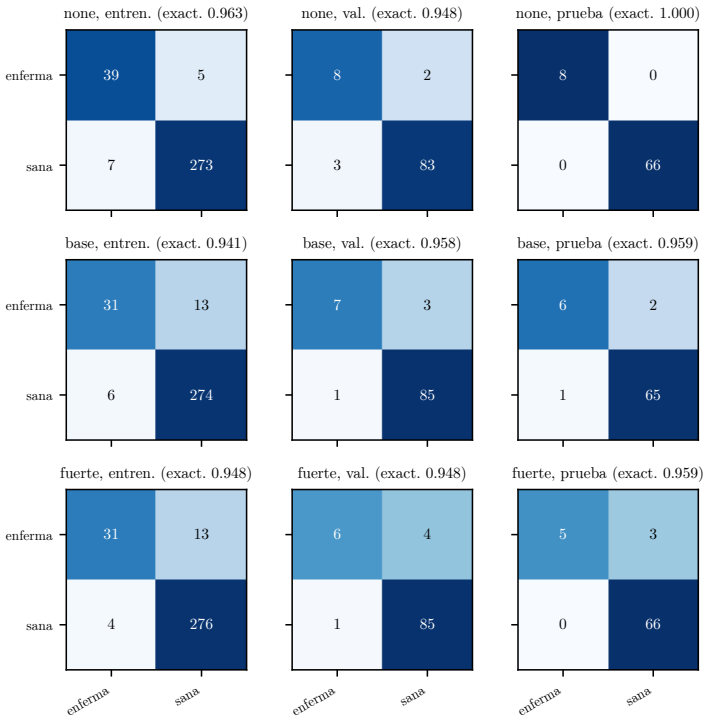


Figura 11: DINOv2 ViT-S/14, sonda lineal.

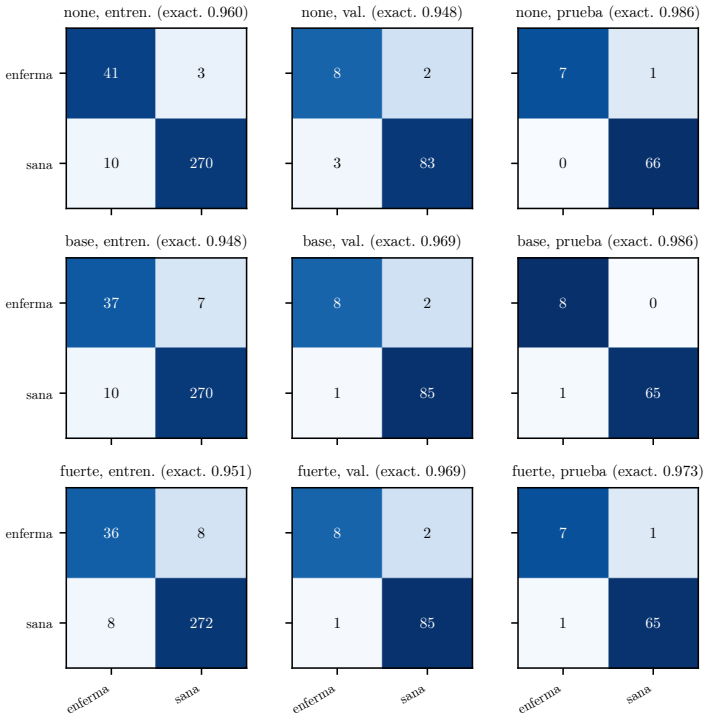


Figura 12: DINOv2 ViT-B/14, sonda lineal.